

Отчёт по выполнению домашнего задания по биоинформатике (BLAST)

Выполнила Линдунен Екатерина Игоревна

Задание 1

Была дана последовательность белка

```
>NP_000537.3 cellular tumor antigen p53 isoform a [Homo sapiens]
MEERQSDPSVEPPLSQETFSDLWKLLPENNVLSPLPSQAMDDLMLSPDDIEQWFTEDPGPDEAPRMPEAA
PPVARAPAAPTPAAPAPAPSWPLSSSVPSQKTYQGSYGFRGLHSGTAKSVTCTYSPALNKMFCQLAKT
CPVQLWVDSTPPPGTRVRAMAIYKQSQHMTVVRRCPHHERCSDSDGLAPPQHLIRVEGNLRVEYLDDRN
TFRHSVVVPYEPPEVGSDCTTIHYNMCMSSCMGGMNRRPILTIITLEDSSGNLLGRNSFEVRVCACPGR
DRRTEENLRKKGERPHHELPPGSTKRALPNNNTSSSPQPKKPLDGEYFTLQIRGRERFEMFRELNEALEL
KDAQAGKEPGGSRAHSSHLKSKKGQSTSRHKKLMFKTEGPDSD
```

Сделали поиск blastp на базе nr (non-redundant proteins):

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	cellular tumor antigen p53 isoform X1 [Gorilla gorilla gorilla]	Gorilla gorilla gorilla	814	814	100%	0.0	99.75%	408	XP_063556659.1
☒	Chain K, Cellular tumor antigen p53 [Homo sapiens]	Homo sapiens	814	814	100%	0.0	100.00%	395	7XZZ_K
☒	Chain C, Cellular tumor antigen p53 [Homo sapiens]	Homo sapiens	814	814	100%	0.0	100.00%	417	8R1F_C
☒	cellular tumor antigen p53 isoform a [Homo sapiens]	Homo sapiens	813	813	100%	0.0	100.00%	393	NP_000537.3

Белок: cellular tumor antigen p53 isoform X1

Организм: *Gorilla gorilla gorilla* (западная горилла)

В таблице у первой строки Max Score = 814, Per. Ident = 99.75%. У следующих двух строк (цепочек K и C из *Homo sapiens*) тоже Score 814, но идентичность 100%. Формально top hit по порядку вывода горилла. Однако фактически человеческие и гориллы белки p53 практически идентичны по значимости (E-value примерно равно 0.0, на самом деле порядка $1e-100$, с учетом миллионов последовательностей на ncbi).

Значение E-value = 0.0 (примерное значение) означает, что вероятность найти столь высокое сходство случайно практически равна нулю. Это говорит о значимом гомологичном выравнивании.

Сырой балл (Raw Score) не подходит для прямой оценки значимости, потому что он зависит от длины выравнивания, используемой матрицы замен (например, BLOSUM62 в этом анализе на blastp) и штрафов за гэпы. E-value же автоматически учитывает размер базы данных и длину запроса, позволяя сравнивать результаты разных бласт-поисков между собой.

Задание 2.

Дана последовательность мРНК:

```
>NM_000518.5 Homo sapiens hemoglobin subunit beta (HBB), mRNA
ACATTTGCTTCTGACACAACCTGTGTTCACTAGCAACCTCAAACAGACACCATGGTGCATCTGACTCCTGA
GGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGTGAACGTGGATGAAGTTGGTGGTGAAGCCCTGGGC
AGGCTGCTGGTGGTCTACCCCTGGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGTCCACTCCTGATG
CTGTTATGGGCAACCCTAAGGTGAAGGCTCATGGCAAGAAAGTGCTCGGTGCCTTTAGTGATGGCCTGGC
TCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGCTGCACTGTGACAAGCTGCACGTGGAT
CCTGAGAACTTCAGGCTCCTGGGCAACGTGCTGGTCTGTGTGCTGGCCCATCACTTTGGCAAAGAATTCA
CCCCACCAGTGCAAGGCTGCCTATCAGAAAGTGGTGGCTGGTGTGGCTAATGCCCTGGCCCACAAGTATCA
CTAAGCTCGCTTTCTTGCTGTCCAATTTCTATTAAGGTTCCCTTTGTTCCCTAAGTCCAATACTAAACT
GGGGGATATTATGAAGGGCCTTGAGCATCTGGATTCTGCCTAATAAAAAACATTTATTTTCATTGCAA
```

Для того чтобы найти гомологичные белки (то есть искать в белковой базе данных), используя в качестве запроса нуклеотидную последовательность, воспользуемся blastx по базе белков nr:

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX37051.1
☒	hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX29557.1
☒	hemoglobin subunit beta [Homo sapiens]	Homo sapiens	301	301	70%	2e-101	100.00%	147	NP_000509.1

hemoglobin subunit beta [Homo sapiens]

Sequence ID: [NP_000509.1](#) Length: 147 Number of Matches: 1

[See 51 more title\(s\)](#) [See all Identical Proteins\(IPG\)](#)

Range 1: 1 to 147 [GenPept](#) [Graphics](#)

[Next Match](#) [Previous Match](#)

Score	Expect	Method	Identities	Positives	Gaps	Frame
301 bits(770)	2e-101	Compositional matrix adjust.	147/147(100%)	147/147(100%)	0/147(0%)	+3
Query 51	MVHLTPEEKSAVTALWGKVNDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPK				230	
Sbjct 1	MVHLTPEEKSAVTALWGKVNDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPK				60	
Query 231	VKAHGKKVLGAFSDGLAHLAHLNKGTFATLSELHCDKLHVDPENFRLLGNVLCVLAHHFG				410	
Sbjct 61	VKAHGKKVLGAFSDGLAHLAHLNKGTFATLSELHCDKLHVDPENFRLLGNVLCVLAHHFG				120	
Query 411	KEFTPPVQAAYQKVVAGVANALAHKYH		491			
Sbjct 121	KEFTPPVQAAYQKVVAGVANALAHKYH		147			

Для выравнивания лучшим найденным белком верной оказалась рамка считывания +3.

Почему этот подход (blastx) надёжнее, чем самостоятельная трансляция мРНК в белок (например, через онлайн-трансляторы) с последующим запуском обычного BLASTp?

- 1) Автоматический перебор всех 6 рамок считывания, blastx пробует все три рамки на прямой цепи и все три на обратной.

- 2) blastx учитывает вырожденность генетического кода, работает на уровне аминокислотных замен, что позволяет обнаруживать гомологию даже при сильных нуклеотидных различиях.
- 3) Интеграция с BLAST-статистикой
blastx выдаёт E-value и другие показатели, скорректированные на размер базы данных и использование шести рамок, что даёт корректную статистическую значимость. При двухэтапном подходе (трансляция + blastp) пользователь может некорректно интерпретировать результаты, если случайно выберет неверную рамку.

Задание 3.

Была дана последовательность:

```
>NP_005359.1 myoglobin isoform 1 [Homo sapiens]
MGLSDGEWQLVLNVWGKVEADIPGHGQEV LIRLFKGH PETLEKFDKFKHLKSEDEMKASEDLKKHGATVL
TALGGILKKKGHNEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFGADAQGAMNKALELFR
KDMASNYKELGFQG
```

Для неё запустили BLASTp по базе белков SwissProt (используя стандартные параметры, матрицу BLOSUM62). Нашли гомолог из организма *Danio rerio*:

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒ RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]	Danio rerio	115	115	95%	9e-35	43.15%	147	Q6VN46.3

RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]

Sequence ID: [Q6VN46.3](#) Length: 147 Number of Matches: 1

Range 1: 5 to 147 [GenPept](#) [Graphics](#) [Next Match](#) [Previous Match](#) [Relat Gene](#)

Score	Expect	Method	Identities	Positives	Gaps
115 bits(289)	9e-35	Compositional matrix adjust.	63/146(43%)	88/146(60%)	3/146(2%)

Query	9	QLVLNVWGKVEADIPGHGQEV LIRLFKGH PETLEKFDKFKHLKSEDEMKASEDLKKHGAT	68
Sbjct	5	DLVLKCGAVEADYAANGGEVLNRLFKEYPDTLKLFPKFSGI-SQGDLAGSPA VAAHGAT	63
Query	69	VLTALGGILKKKGHNEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFGADA	128
Sbjct	64	VLKKGELGELLKAKGDHAALLKPLANTHANIHKVALNNFRLITEVLVKVMAEKAGLD--AAG	121
Query	129	QGAMNKALELFRKDMASNYKELGFQG	154
Sbjct	122	QGALRRVMDAVIDGIDGYYKEIGFAG	147

Теперь изменим в параметрах алгоритма матрицу на PAM30:

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒ RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]	Danio rerio	119	119	97%	2e-29	41.61%	147	Q6VN46.3
☒ RecName: Full=Cytoglobin-1; AltName: Full=Nitric oxygen dioxygenase CYGB; AltName: Full=Nitrite reductase CYGB; Alt...	Danio rerio	72.7	72.7	99%	1e-14	26.75%	174	Q8UUR3.2

RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]

Sequence ID: [Q6VN46.3](#) Length: 147 Number of Matches: 1

Range 1: 2 to 147 [GenPept](#) [Graphics](#)

[▼ Next Match](#) [▲ Previous Match](#)

[Relat](#)

[Gene](#)

Score	Expect	Method	Identities	Positives	Gaps
119 bits(274)	2e-29	Compositional matrix adjust.	62/149(42%)	73/149(48%)	3/149(2%)
Query 6	GEWQLVLNVWGKVEADIPGHGQEVLI	RLFKGHPETLEKFDKFKHLKSEDEMKASEDLKKH	65		
	+ LVL WG VEAD G EVL RLFK P+TL F KF	S+ ++ S H			
Sbjct 2	ADHDLVLKCGAVEADYAANGGEVLNRLF	KEYPDTLKLFPKFSGI-SQGDLAGSPAVAAH	60		
Query 66	GATVLTALGGILKKKGHHEAEIKPLAQSHATKH	KIPVKYLEFISECIIQVLQSKHPGDFG	125		
	GATVL LG LK KG H A KPLA HA HK+	I E + V+ K			
Sbjct 61	GATVLKKGELLLKAKGDHAALLKPLANTHANIH	KVALNNFRLITEVLVKVMAEK--AGLD	118		
Query 126	ADAQGAMNKALELFRKDMASNYKELGFQG	154			
	A QGA+ ++ D YKE GF G				
Sbjct 119	AAGQGALRRVMDAVIDGIDGYYKEIGFAG	147			

Видим, что Score немного увеличился (со 115 до 119), Identities немного уменьшился (с 43% до 42%), E-value увеличился на 6 порядков.

РАМ30 построена на эволюционном расстоянии в 30 замен на 100 ак. Она хорошо различает консервативные замены, но чувствительна к редким заменам, поэтому для близких гомологов.

BLOSUM62 рассчитана из блоков с 62% идентичности (блоки замен, не превышающие 62% сходства). Она менее строгая, чем РАМ30, т.е. позволяет выявлять более отдалённые гомологи.

Задание 4.

Дана последовательность:

>NP_009225.1 breast cancer type 1 susceptibility protein isoform 1 [Homo sapiens]
 MDLSALRVEEVQNVINAMQKILECPICLELIKEPVSTKCDHIFCKFCMLKLLNQKKGPSQCPLCKNDITK
 RSLQESTRFSQLVEELLKIICAFQLDTGLEAYNSYNFAKKENNSPEHLKDEVSIQSMGYRNRKRLLQS
 EPENPSLQETSLSVQLSNLGTVRTLRTKQRIQPQKTSVYIELGSDSSEDTVNKATYCSVGQELLQITPQ
 GTRDEISLDSAKKAACEFSETDVTNTEHHQPSNNDLNTTEKRAAERHPEKYQGSSVSNLHVEPCGTNTHA
 SSLQHENSLLLLTKDRMNVEKAFCNKSQKPLARSQHNRWAGSKETCNDRRTPSTEKKVDLNADPLCER
 KEWNKQKLPCSENPRDTEVPWITLNSSIQKVNEWFSRDELLGSDSDHGESESNKVADVLDVLNEVD
 EYSGSSEKIDLLASDPHEALICKSERVHKS SVESNIEDKIFGKTYRKKASLPNL SHVTENLIIGAFVTEP
 QIIQERPLTNKLKRKRRTSGLHPEDFIKKADLAVQKTPEMINQGTNQT EQNGQVMNITNSGHENKTKGD
 SIQNEKNPNPIESLEKESAFKTKAEPISSSISNMELELNHNSKAPKKNRLRRKSSTRHIALELVVSRN
 LSPPNCTELQIDSCSSSEEIKKKYNQMPVRHSRNQLMEGKEPATGAKKSNKPNEQTSKRHDSDTFPEL
 KLTNAPGSFTKCSNTSELKEFVNPSLPREEKEEKLTVKVSNNAEADPKDMLSGSERVLQTERSVESSSIS
 LVPGTDYGTQESISLLEVSTLGKAKTEPNKCVSQCAAFENPKGLIHGCSKDNRNDEGFKYPLGHEVNHS
 RETSIEMEESELDAQYLQNTFKVSKRQSFAPFSNPGNAEEECATFSAHSGSLKKQSPKVTFECEQKEENQ
 GKNESNIKPQVTVNITAGFPVVGQKDKPVDNAKCSIKGGSRFCLSSQFRGNETGLITPNKHGLLQNPYRI
 PPLFPIKSFVKTKCKNLL EENFEHSMSPEREMGNENIPSTVSTISRNNIRENVFKEASSNINEVGSS
 TNEVGSSSINEIGSSDENIQAE LGRNRGPKLNAMLRLGVLQPEVYKQSLPGSNCKHPEIKKQEEYEEVVQTV
 NTDFSPYLISDNLEQPMGSSHASQVCSETPDDLDDGEIKEDTSFAENDIKESSAVFSKVQKGELSRSP
 SPFTHTHLAQGYRRGAKKLESSEENL SSED EELPCFQHL LFGKVNIP SQSTRHSTVATECLSKNTEENL
 LSLKNSLNDCSNQVILAKASQEHHLSEETKCSASLFSQCSELEDLTANTNTQDPFLIGSSKQMRHQSES
 QGVGLSDKELVSDDEERGTGLEENNQEEQSMDSNLGEAASGCESETSVSEDCSGLSSQSDILTTQQRDTM
 QHNLIKLQQEMAELEAVLEQHGSQPSNSYPSIISDSSALEDLRNPEQSTSEKAVLTSQKSSEYPISQNPE
 GLSADKFEVSADSSTSKNKEPGVERSSPSKCPSLDDRWMHSCSGSLQNRNYP SQEELIKVVDVEEQQLE
 ESGPHDLTETSYLPRQDLEGTPLYESGISLFSDDPESDPSEDRAPE SARVGNIPSSSALKVPQLKVAES
 AQSPAAHTTDTAGYNAMEESVSREKPELTASTERNKRMVMVSGLTPEEFMLVYKFARKHHITLTNL I
 TEETTHVVMKTD AEFVCERTLKYFLGIAGGKWVVS YFWVTQSIKERKMLNEHDFEVRGDVVNGRNHQGPK
 RARESQRKIFRGL EICCYGPFTNMPTDQLEWVQLCGASVVKELSSFTLTGTGVHPIVVQPD AWTEDNG
 FHAIGQMCEAPVVTREWVLD SVALYQCQELDTYLIPQIPHSY

Цель: найти ортолог у плодовой мушки (*Drosophila melanogaster*)

Для этого запустим BLASTp с аминокислотной последовательностью, по базе nr на матрице BLOSUM62 и искать будем конкретно этот организм:

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
✓	uncharacterized protein Dmel_CG44271 [Drosophila melanogaster]	Drosophila mela...	57.8	57.8	2%	2e-09	54.35%	106	NP_001285689.1
✓	MIP36205p1, partial [Drosophila melanogaster]	Drosophila mela...	52.4	52.4	2%	1e-07	54.76%	104	AFP33460.1
✓	degringolade, isoform A [Drosophila melanogaster]	Drosophila mela...	52.4	52.4	3%	3e-06	35.09%	319	NP_649596.1
✓	degringolade, isoform B [Drosophila melanogaster]	Drosophila mela...	52.0	52.0	3%	3e-06	35.09%	312	NP_731017.1
✓	Sex combs extra [Drosophila melanogaster]	Drosophila mela...	52.0	52.0	3%	5e-06	37.31%	435	NP_477509.1
✓	DRING protein [Drosophila melanogaster]	Drosophila mela...	52.0	52.0	3%	5e-06	37.31%	435	CAA04797.1
✓	degringolade, isoform D [Drosophila melanogaster]	Drosophila mela...	49.7	49.7	3%	7e-06	35.09%	205	NP_001287188.1
✓	microcephalin, isoform C [Drosophila melanogaster]	Drosophila mela...	51.6	51.6	6%	1e-05	33.04%	981	NP_001163122.1
✓	microcephalin, isoform D [Drosophila melanogaster]	Drosophila mela...	51.6	51.6	6%	1e-05	33.04%	1028	NP_001163123.1
✓	elfless, isoform B [Drosophila melanogaster]	Drosophila mela...	48.9	48.9	2%	2e-05	45.65%	229	NP_001163003.1
✓	AT24563p [Drosophila melanogaster]	Drosophila mela...	48.1	48.1	2%	2e-05	45.65%	187	AAM29303.1
✓	uncharacterized protein Dmel_CG46383 [Drosophila melanogaster]	Drosophila mela...	43.1	43.1	2%	8e-05	41.86%	65	NP_001356919.1
✓	uncharacterized protein Dmel_CG9014, isoform B [Drosophila melanogaster]	Drosophila mela...	47.0	47.0	4%	1e-04	35.62%	328	NP_001285905.1

Возьмем первый охарактеризованный белок – degringolade, isoform A:

degringolade, isoform A [Drosophila melanogaster]

Sequence ID: [NP_649596.1](#) Length: 319 Number of Matches: 1

[See 2 more title\(s\)](#) [See all Identical Proteins\(IPG\)](#)

Range 1: 261 to 314 [GenPept](#) [Graphics](#)


[Next Match](#) [Previous Match](#)

Score	Expect	Method	Identities	Positives	Gaps
52.4 bits(124)	3e-06	Compositional matrix adjust.	20/57(35%)	36/57(63%)	5/57(8%)
Query 19	QKILECPICLELI--KEPVSTKCDHIFCKFCMLKLLNQKKGPSQCPLCKNDITKRSL				73
	+++ +CPIC++ + +EPVSTKC H+FC+ C+ + + +CP+C +T R				
Sbjct 261	EELYKCPICMDSVSKREPVS TKCGHVFCRECIETAI---RATHKCPICNKKLTARQF				314

Query cover составил 3%, а per ident 35%

Визуализируем выравнивание:

degringolade, isoform A [Drosophila melanogaster]
gi|21357313|ref|NP_649596.1|



Видим, что белок сохранил только участок в 3%, у мушки есть белок, который содержит один небольшой консервативный домен, похожий на домен BRCA1 человека. Это свидетельствует о том, что это не полноценный ортолог BRCA1 у дрозофилы. Найденный белок содержит один консервативный более-менее консервативный домен, гомологичный домену BRCA1, но вряд ли может быть его полноценным функциональным аналогом (по определению ортологов они должны быть функциональными аналогами).